

多源反馈收集 (MFC)

(x, y^*)

多温度采样

$\{y_1, \dots, y_4\} \times 4$

拒绝滤波

Multi-form Feedback Collector

MFC

规则反馈分支

ROUGE-1 unigram F_1

ROUGE-2 bigram F_1

ROUGE-L LCS F_1

自奖励分支

Token LogP

$\log P(y_i|x)$

Seq LogP

$\text{avg } \sum \log P$

反馈融合器

$$s_{fused} = \alpha s_{rule} + (1-\alpha)s_{self}$$

自适应反馈融合 (AFF)

Adaptive Feedback Fusion

AFF

注意力权重

$$w = \text{softmax}(W[s_{rule}; s_{self}] + b)$$



分数融合

$$s_{fused} = w_{rule}s_{rule} + w_{self}s_{self}$$



$$\mathbf{y}^+ \leftarrow \arg\max s_{fused}$$

$$\mathbf{y}^- \leftarrow \arg\min s_{fused}$$

s_{rule}, s_{self}



权重梯度

(x, y^+, y^-)



模型反馈

偏好优化微调 (POF)

Preference Optimization Fine-tuning

POF

DPO 损失

$$L_{DPO} = -E[\log \sigma(\text{br}(y^+) - \text{br}(y^-))]$$



$(\beta=0.1)$

LoRA 参数更新

$(\text{rank}=8, \alpha=16)$



Q K V → LoRA

$\text{lr}=5\text{e-}6 \cdot \text{epochs}=3 \cdot \text{batch}=16$



Optimized π_0

迭代训练闭环 (Iterative Training Loop)

模型评估

ROUGE / LogP 评分



数据重采样

$T \in \{0.5, 0.8, 1.2, 1.8\}$



偏好重构

MFC → AFF → POF



超参数调整

$\beta / \text{rank} / \text{lr}$